REGRESYON ÖDEVİ

HAZIRLAYANLAR

Ayşenur Altınkaya
Gökhan Tanrıöven
Giray Baysal
Kaan Boztaş

Veri Setini Tanıyalım

Veri seti özeti:

Bu çalışmada kullanılan veri seti, betonun **basınç dayanımını** etkileyen temel bileşenleri ve kür süresini içeren nicel bir veri setidir.

Amaç:

Bu çalışmada, betonun basınç dayanımını tahmin etmek amacıyla çoklu regresyon analizi uygulanmıştır. Bu kapsamda, beton karışımında yer alan çimento, su, agrega türleri, katkı maddeleri ve kür süresi gibi bileşenler arasındaki ilişkiler modellenerek, bu değişkenlerin betonun basınç dayanımı üzerindeki etkileri incelenmiştir.
Kurulan regresyon modeli sayesinde, betonun dayanımını etkileyen temel faktörler belirlenmekte ve bu faktörler kullanılarak farklı karışım ve kür koşulları altında betonun gelecekteki basınç dayanımının tahmin edilmesi amaçlanmıştır.

Veri Seti Hakkında

```
> head(data)
  Basınç_Dayanımı Çimento Yüksek_Fırın_Cürufu Uçucu_Kül      Su Süper_Akışkanlaştırıcı
1          79.991 540.001                0.001     0.001 162.001                 2.501
2          61.891 540.001                0.001     0.001 162.001                 2.501
3          40.271 332.501              142.501     0.001 228.001                 0.001
4          41.051 332.501              142.501     0.001 228.001                 0.001
5          44.301 198.601              132.401     0.001 192.001                 0.001
6          47.031 266.001              114.001     0.001 228.001                 0.001
  İri_Agrega İnce_Agrega Kür_Süresi
1   1040.001     676.001     28.001
2   1055.001     676.001     28.001
3    932.001     594.001    270.001
4    932.001     594.001    365.001
5    978.401     825.501    360.001
6    932.001     670.001     90.001
```

Tanımlayıcı Grafikler

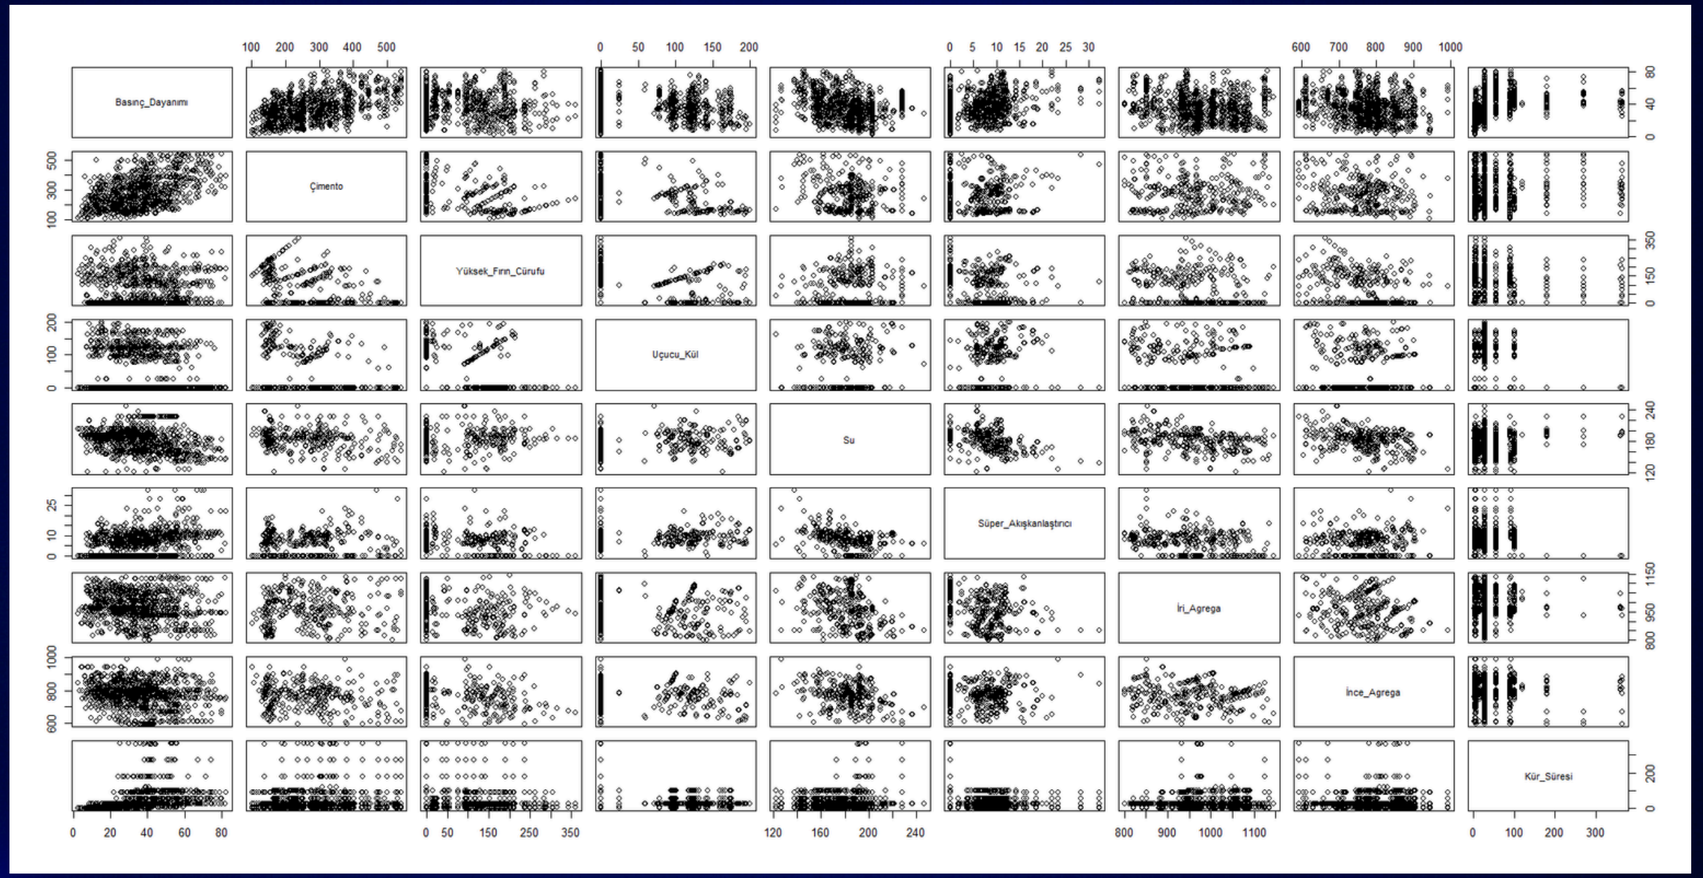

Çimento vs Basınç: Çimento miktarı ve basınç arasında pozitif bir ilişki görülmektedir. Çimento miktarı arttıkça basınç dayanımı da yukarı doğru tırmanıyor.

Kür Süresi vs Basınç: Gün sayısı arttıkça dayanımın arttığı net bir şekilde görülüyor.

Tanımlayıcı Grafikler

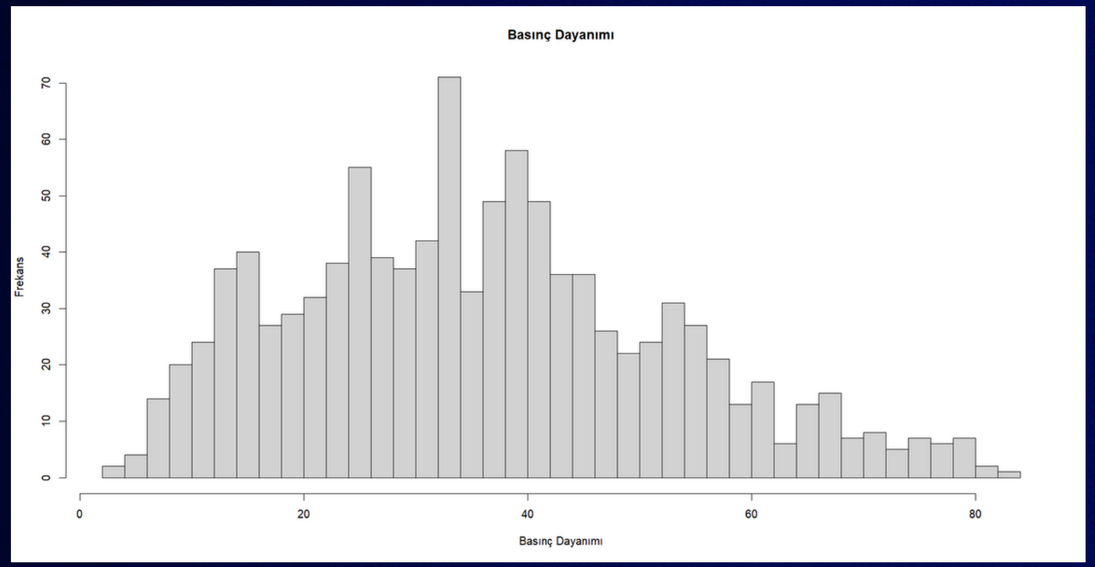

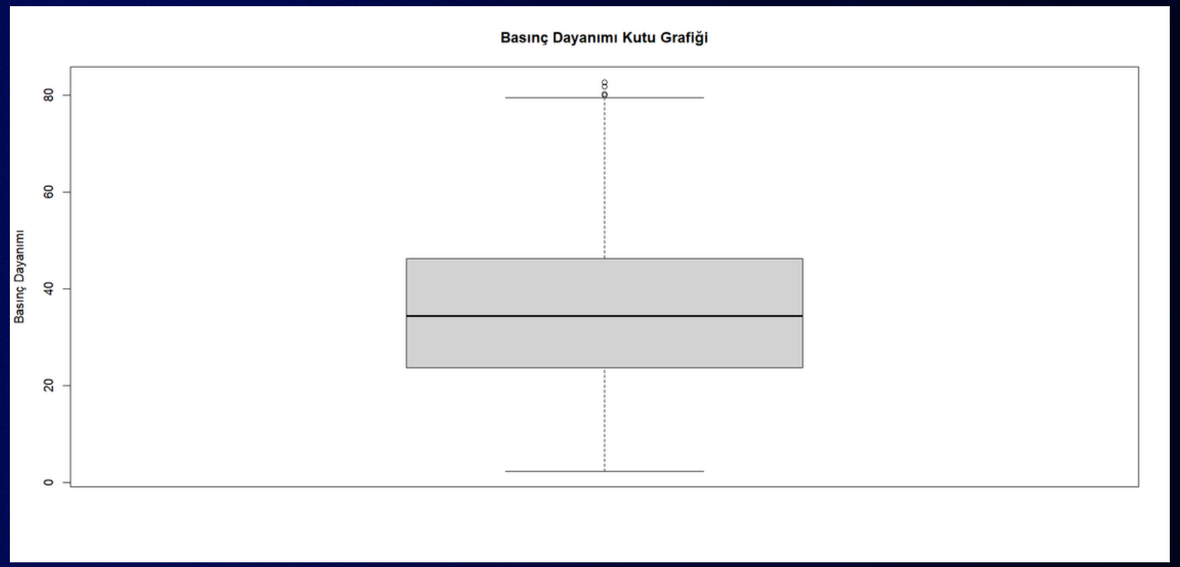

Histogram, Basınç Dayanımı değişkeninin dağılımını göstermektedir. Dağılım simetrik değildir ve sağa çarpıklık görülmektedir. Bu durum, basınç dayanımının normal dağılmadığını göstermektedir.

Kutu grafiği, Basınç Dayanımı değerlerinin çoğunun belirli bir aralıkta toplandığını, üst uçta yer alan sınırlı sayıdaki gözlemin ise dağılımda sağa çarpıklığa işaret ettiğini göstermektedir.

Tanımlayıcı Grafikler

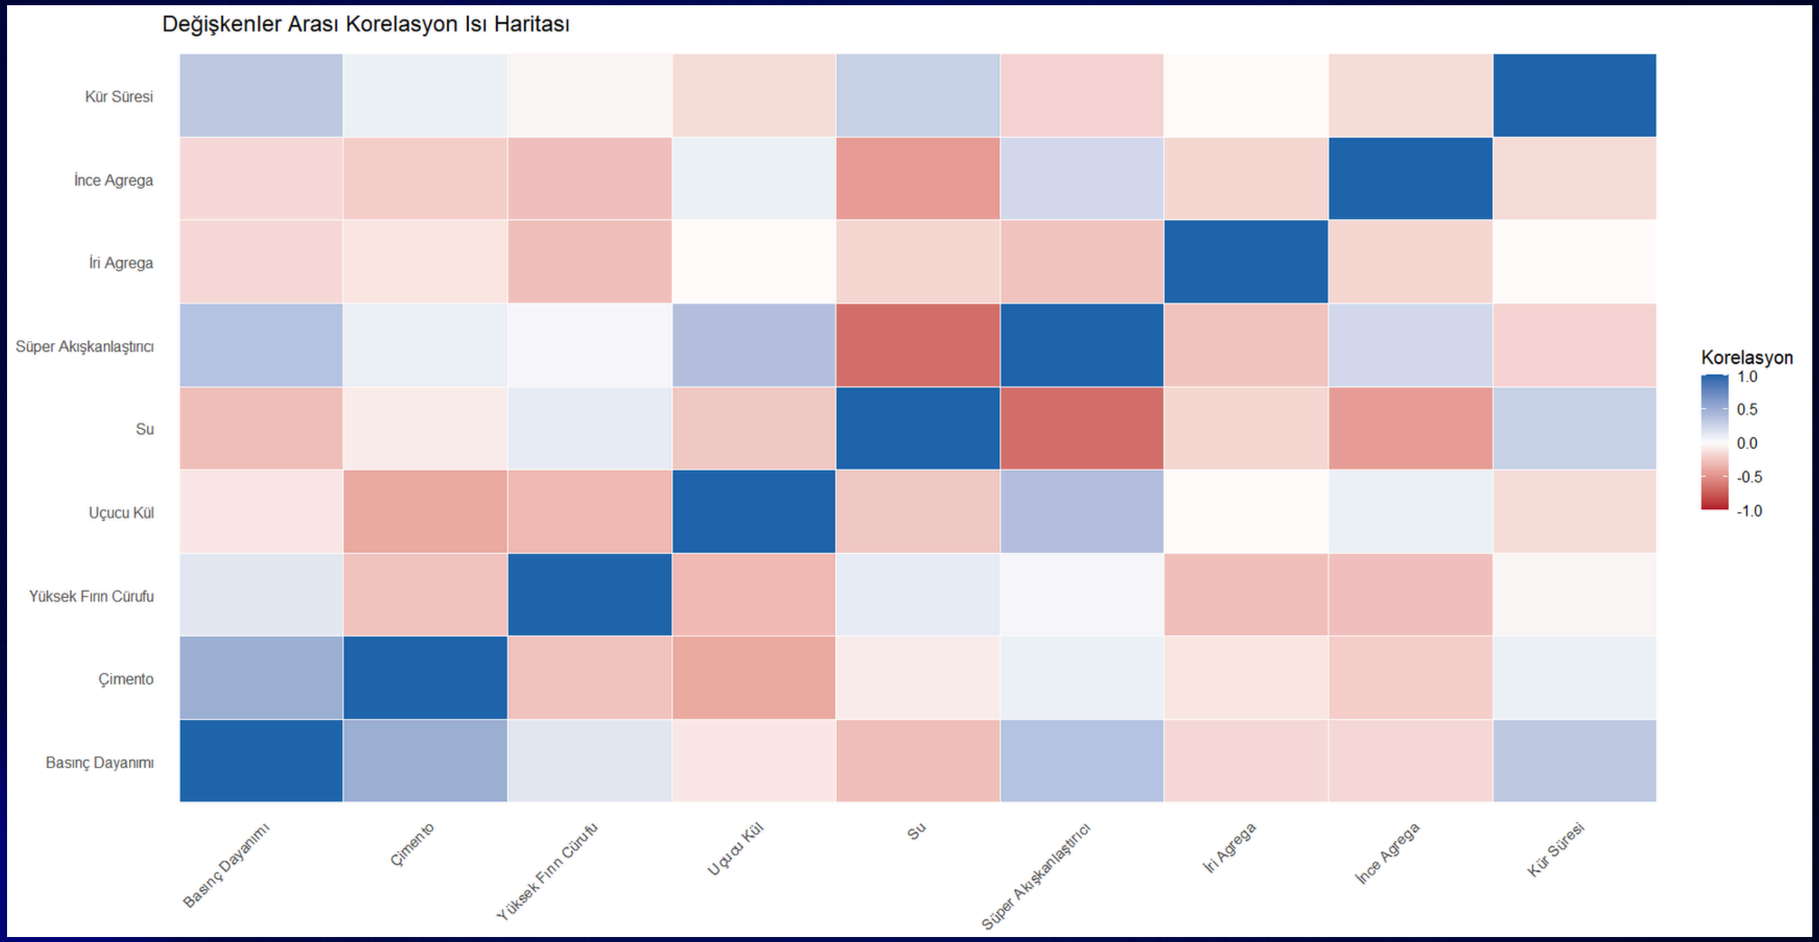

İlk Model

```
> summary(model)

Call:
lm(formula = Basınç_Dayanımı ~ Çimento + Yüksek_Fırın_Cürufu +
    Uçucu_Kül + Su + Süper_Akışkanlaştırıcı + İri_Agrega + İnce_Agrega +
    Kür_Süresi, data = train)

Residuals:
    Min      1Q  Median      3Q     Max
-30.775  -6.206   0.779   6.710  35.059

Coefficients:
                        Estimate Std. Error t value Pr(>|t|)
(Intercept)           -36.665702  29.253116  -1.253 0.210446
Çimento                 0.119007   0.009468  12.569  < 2e-16 ***
Yüksek_Fırın_Cürufu     0.103612   0.011214   9.239  < 2e-16 ***
Uçucu_Kül               0.085797   0.014096   6.087 1.82e-09 ***
Su                     -0.111204   0.044035  -2.525 0.011760 *
Süper_Akışkanlaştırıcı  0.406345   0.105975   3.834 0.000136 ***
İri_Agrega              0.022639   0.010381   2.181 0.029502 *
İnce_Agrega             0.022074   0.011854   1.862 0.062965 .
Kür_Süresi              0.120509   0.006562  18.364  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 10.12 on 763 degrees of freedom
Multiple R-squared:  0.6216,    Adjusted R-squared:  0.6177
F-statistic: 156.7 on 8 and 763 DF,  p-value: < 2.2e-16
```

Modelin genel değerlendirmesi:

Açıklanan varyans oranı (R^2) = 0.6216
Basınç dayanımındaki değişimin yaklaşık %62’si bağımsız değişkenler tarafından açıklanmaktadır.

- Varyans homojenliği sağlanmıyor.
- Artıklar normal dağılmıyor.
- p-value < 0.05 olan katsayılar anlamlı kabul edilir. Model genel olarak anlamlı olmasına rağmen, iki değişken istatistiksel olarak anlamlı değildir:
  Basınç Dayanımı (p=0.2104)
  İnce Agrega (p = 0.0629)

```
> bptest(model)

        studentized Breusch-Pagan test

data:  model
BP = 104.46, df = 8, p-value < 2.2e-16
```

```
> shapiro.test(train$Basınç_Dayanımı)

        Shapiro-Wilk normality test

data:  train$Basınç_Dayanımı
W = 0.98195, p-value = 3.68e-08
```

İlk Model

```
> anova(model)
Analysis of Variance Table

Response: Basınç_Dayanımı
                          Df Sum Sq Mean Sq  F value    Pr(>F)
Çimento                    1  51032   51032 498.3124 < 2.2e-16 ***
Yüksek_Fırın_Cürufu        1  16097   16097 157.1817 < 2.2e-16 ***
Uçucu_Kül                  1  15757   15757 153.8616 < 2.2e-16 ***
Su                         1   9134    9134  89.1903 < 2.2e-16 ***
Süper_Akışkanlaştırıcı     1   1263    1263  12.3315 0.0004716 ***
İri_Agrega                 1    437     437   4.2664 0.0392108 *
İnce_Agrega                1    118     118   1.1536 0.2831443
Kür_Süresi                 1  34535   34535 337.2245 < 2.2e-16 ***
Residuals                763  78139     102
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

```
> vif(model)
                Çimento     Yüksek_Fırın_Cürufu               Uçucu_Kül
                7.369890                7.157315                6.192801
                      Su Süper_Akışkanlaştırıcı            İri_Agrega
                6.464365                2.875256                4.766997
           İnce_Agrega              Kür_Süresi
                6.876622                1.077122
```

Tanımlayıcı Grafikler

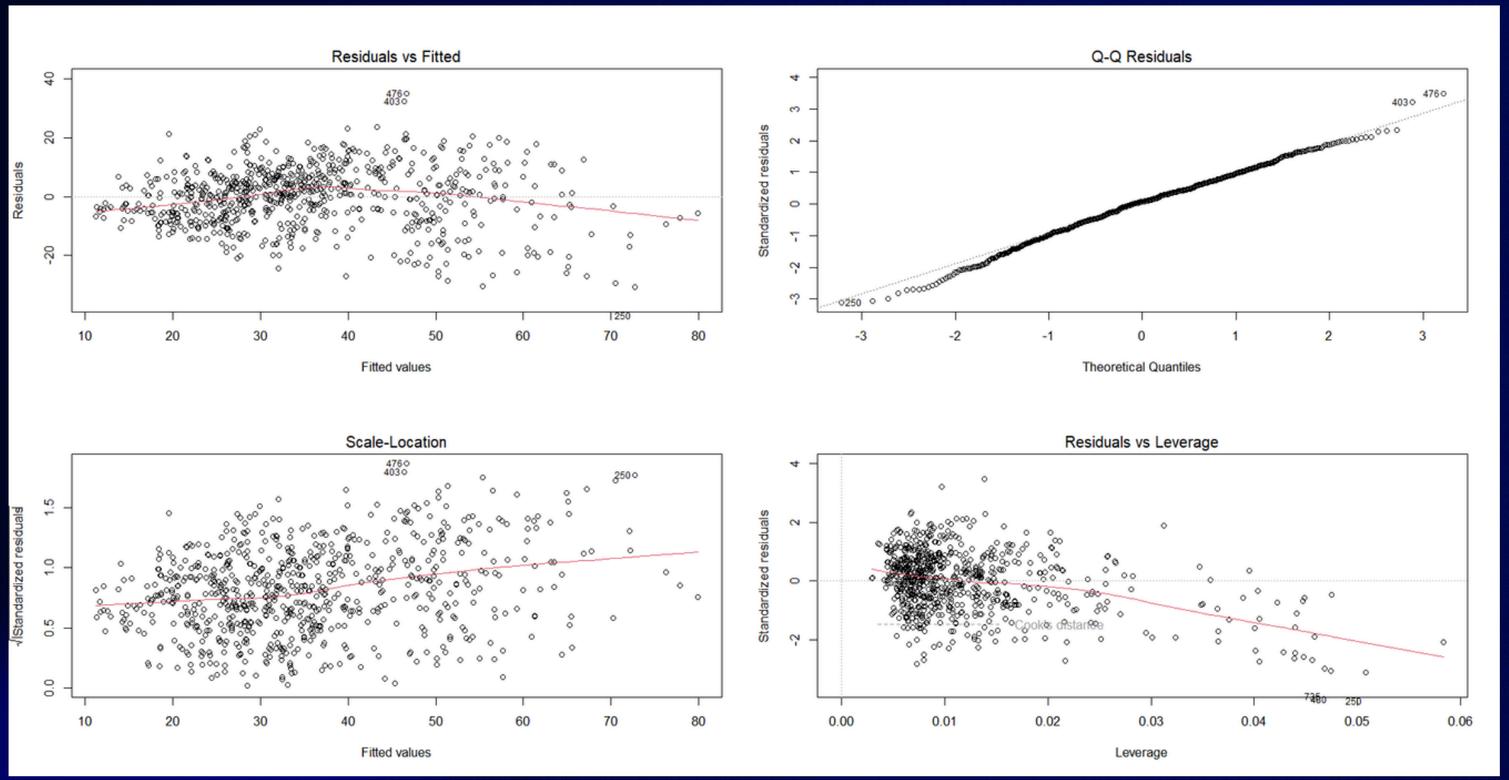

- **Residuals vs Fitted (Artıklar – Tahminler)**

Artıkların tahmin edilen değerler etrafında tamamen rastgele dağılmadığı, özellikle yüksek tahmin değerlerinde bir eğilim oluştuğu görülmektedir.

- **Q–Q Plot (Artıkların Normalliği)**

Artıklar orta bölgede normale yakın dağılmakla birlikte, uç değerlerde sapmalar gözlenmektedir.

- **Scale–Location (Varyans Homojenliği)**

Artıkların yayılımı tahmin edilen değerler arttıkça büyümektedir; bu durum varyansın sabit olmadığını göstermektedir.

- **Residuals vs Leverage (Etkili Gözlemler)**

Yüksek kaldıraç ve büyük artık değerlerine sahip gözlemler nedeniyle, modele aşırı etki eden gözlemlerin varlığından şüphelenilmektedir.

Veri Setinin Güncellenmesi

Aykırı gözlemler, regresyon modelinden elde edilen standartlaştırılmış artıklar kullanılarak belirlenmiştir. |r| > 3 koşulunu sağlayan gözlemler analiz dışı bırakılmıştır.

```
> outlier_index <- which(abs(rstd) > 3)
> outlier_index
250 403 476 480
```

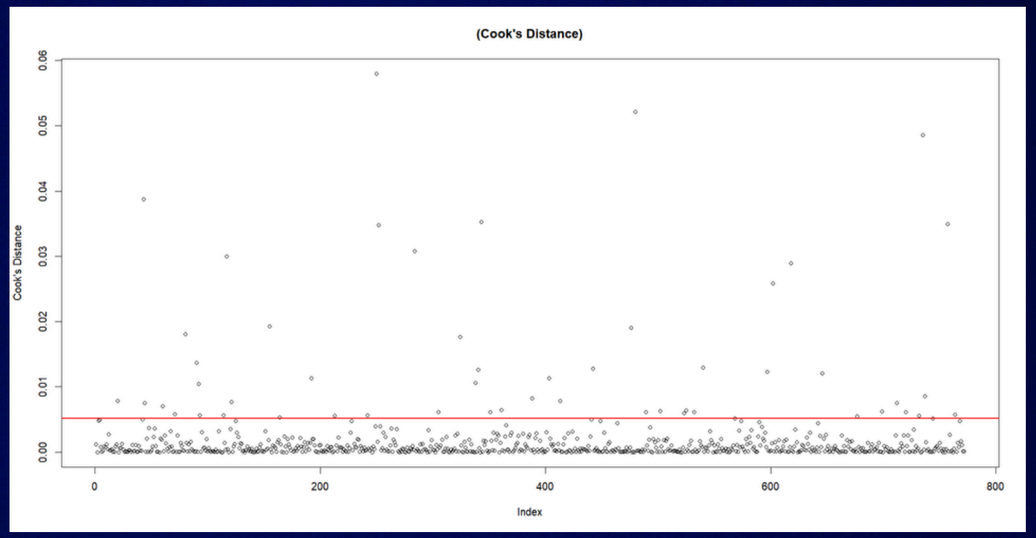


```
> cat("Silinen gözlem sayısı:", nrow(train) - nrow(train_clean), "\n")
Silinen gözlem sayısı: 52
```

Standartlaştırılmış artıklar ve Cook’s Distance ölçütleri kullanılarak modele orantısız etki eden 52 gözlem eğitim setinden çıkarılmıştır.

Alternatif Model

```
> summary(alternatif_model)

Call:
lm(formula = log(Basınç_Dayanımı) ~ Çimento + Yüksek_Fırın_Cürufu +
    Uçucu_Kül + Su + Süper_Akışkanlaştırıcı + İri_Agrega + İnce_Agrega +
    Kür_Süresi, data = train_clean)

Residuals:
     Min       1Q   Median       3Q      Max
-1.45758 -0.18811  0.07386  0.22037  0.64962

Coefficients:
                        Estimate Std. Error t value Pr(>|t|)
(Intercept)            2.217e+00  1.042e+00   2.127  0.03376 *
Çimento                3.687e-03  3.369e-04  10.945  < 2e-16 ***
Yüksek_Fırın_Cürufu    2.958e-03  4.006e-04   7.384 4.30e-13 ***
Uçucu_Kül              2.868e-03  4.942e-04   5.804 9.73e-09 ***
Su                    -4.692e-03  1.576e-03  -2.977  0.00301 **
Süper_Akışkanlaştırıcı 1.193e-02  3.771e-03   3.163  0.00163 **
İri_Agrega             3.205e-04  3.628e-04   0.883  0.37730
İnce_Agrega            9.407e-05  4.200e-04   0.224  0.82283
Kür_Süresi             5.793e-03  2.797e-04  20.708  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.3231 on 711 degrees of freedom
Multiple R-squared:  0.6532,    Adjusted R-squared:  0.6493
F-statistic: 167.4 on 8 and 711 DF,  p-value: < 2.2e-16
```

Modelin genel değerlendirmesi:

Açıklanan varyans oranı (R^2) = 0.6532
Model, basınç dayanımı değişiminin %65'ini açıklamaktadır.
Adjusted R^2 değeri de oldukça benzer (%64.93), modelin bağımsız değişkenler açısından iyi bir performans sergilediğini gösterir.

- R^2 arttı.
- Varyans homojenliği sağlanmıyor.
- Artıklar normal dağılmıyor.
- Bağımlı değişken istatistiksel olarak anlamlı oldu.
- İki değişken istatistiksel olarak anlamlı değil.

```
> bptest(alternatif_model)

        studentized Breusch-Pagan test

data:  alternatif_model
BP = 34.78, df = 8, p-value = 2.933e-05
```

```
> shapiro.test(alternatif_model$residuals)

        Shapiro-Wilk normality test

data:  alternatif_model$residuals
W = 0.94352, p-value = 6.329e-16
```

Stepwise Model

```
> summary(step_model)

Call:
lm(formula = Basınç_Dayanımı ~ Çimento + Kür_Süresi + Süper_Akışkanlaştırıcı + 
    Yüksek_Fırın_Cürufu + Su + Uçucu_Kül, data = train_clean)

Residuals:
    Min      1Q  Median      3Q     Max 
-25.339  -5.178   0.625   5.463  22.919 

Coefficients:
                       Estimate Std. Error t value Pr(>|t|)    
(Intercept)           23.556276   4.128348   5.706 1.70e-08 ***
Çimento                0.107248   0.004095  26.190  < 2e-16 ***
Kür_Süresi             0.176161   0.007091  24.842  < 2e-16 ***
Süper_Akışkanlaştırıcı 0.406270   0.089169   4.556 6.13e-06 ***
Yüksek_Fırın_Cürufu    0.089306   0.004900  18.225  < 2e-16 ***
Su                    -0.204589   0.020769  -9.850  < 2e-16 ***
Uçucu_Kül              0.065166   0.007540   8.643  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 8.219 on 713 degrees of freedom
Multiple R-squared:  0.7443,    Adjusted R-squared:  0.7421 
F-statistic: 345.8 on 6 and 713 DF,  p-value: < 2.2e-16
```

Modelin genel değerlendirmesi:

Açıklanan varyans oranı (R^2) = 0.7443
Model, basınç dayanımı değişiminin %74'ünü açıklamaktadır.
Adjusted R^2 değeri de oldukça benzer (%74.21), modelin bağımsız değişkenler açısından iyi bir performans sergilediğini gösterir.

- R^2 arttı.
- Varyans homojenliği sağlanmıyor.
- Artıklar normal dağılmıyor.
- Değişkenler istatistiksel olarak anlamlı.

```
> bptest(step_model)

        studentized Breusch-Pagan test

data:  step_model
BP = 74.405, df = 6, p-value = 5.089e-14
```

```
> shapiro.test(step_model$residuals)

        Shapiro-Wilk normality test

data:  step_model$residuals
W = 0.99549, p-value = 0.03399
```

Ağırlıklı En Küçük Kareler (WLS) Yöntemi ile Model

```
> summary(wls_model)

Call:
lm(formula = Basınç_Dayanımı ~ Çimento + Yüksek_Fırın_Cürufu +
    Uçucu_Kül + Su + Süper_Akışkanlaştırıcı + İri_Agrega + İnce_Agrega +
    Kür_Süresi, data = train_clean, weights = weights_wls)

Weighted Residuals:
     Min       1Q   Median       3Q      Max
-2.80958 -0.63287  0.04972  0.68375  2.66645

Coefficients:
                        Estimate Std. Error t value Pr(>|t|)
(Intercept)           -28.194088  25.061451  -1.125  0.26097
Çimento                 0.124999   0.008233  15.183  < 2e-16 ***
Yüksek_Fırın_Cürufu     0.103009   0.009592  10.739  < 2e-16 ***
Uçucu_Kül               0.077896   0.011706   6.655 5.67e-11 ***
Su                     -0.123449   0.037643  -3.279  0.00109 **
Süper_Akışkanlaştırıcı  0.505452   0.095022   5.319 1.40e-07 ***
İri_Agrega              0.015547   0.008667   1.794  0.07327 .
İnce_Agrega             0.017455   0.010121   1.725  0.08504 .
Kür_Süresi              0.203781   0.007794  26.145  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.997 on 711 degrees of freedom
Multiple R-squared:  0.7713,    Adjusted R-squared:  0.7688
F-statistic: 299.8 on 8 and 711 DF,  p-value: < 2.2e-16
```

Modelin genel değerlendirmesi:

Açıklanan varyans oranı (R^2) = 0.7713
Model, basınç dayanımı değişiminin %77'sini açıklamaktadır.
Adjusted R^2 değeri de oldukça benzer (%76.88), modelin bağımsız değişkenler açısından iyi bir performans sergilediğini gösterir.

- R^2 arttı.
- Varyans homojenliği sağlandı.
- Artıklar normal dağılmıyor.
- Üç değişken istatistiksel olarak anlamlı değil.

```
> bptest(wls_model)

        studentized Breusch-Pagan test

data:  wls_model
BP = 3.1359, df = 8, p-value = 0.9255
```

```
> shapiro.test(wls_model$residuals)

        Shapiro-Wilk normality test

data:  wls_model$residuals
W = 0.98714, p-value = 5.823e-06
```

Dönüşüm ile WLS Model

```
> summary(wls_final_model)

Call:
lm(formula = Basınç_Dayanımı ~ Çimento + Yüksek_Fırın_Cürufu +
    Uçucu_Kül + poly(Su, 2) + Süper_Akışkanlaştırıcı + İri_Agrega +
    İnce_Agrega + log(Kür_Süresi), data = train_clean, weights = weights_wls)

Weighted Residuals:
    Min      1Q  Median      3Q     Max
-2.2406 -0.5021 -0.0307  0.4990  3.2641

Coefficients:
                        Estimate Std. Error t value Pr(>|t|)
(Intercept)           -1.054e+02  1.448e+01  -7.282 8.75e-13 ***
Çimento                1.400e-01  6.260e-03  22.365  < 2e-16 ***
Yüksek_Fırın_Cürufu    1.185e-01  7.309e-03  16.208  < 2e-16 ***
Uçucu_Kül              9.089e-02  8.914e-03  10.196  < 2e-16 ***
poly(Su, 2)1          -5.901e+01  1.556e+01  -3.793 0.000161 ***
poly(Su, 2)2           3.005e+01  6.670e+00   4.505 7.76e-06 ***
Süper_Akışkanlaştırıcı 1.642e-01  7.469e-02   2.198 0.028295 *
İri_Agrega             3.054e-02  6.607e-03   4.623 4.50e-06 ***
İnce_Agrega            4.189e-02  7.753e-03   5.403 8.94e-08 ***
log(Kür_Süresi)        8.024e+00  1.984e-01  40.452  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.7583 on 710 degrees of freedom
Multiple R-squared:  0.8679,    Adjusted R-squared:  0.8662
F-statistic: 518.4 on 9 and 710 DF,  p-value: < 2.2e-16
```

Modelin genel değerlendirmesi:

Açıklanan varyans oranı (R^2) = 0.8679
Model, basınç dayanımı değişiminin %86'sını açıklamaktadır.
Adjusted R^2 değeri de oldukça benzer (%86.62), modelin bağımsız değişkenler açısından iyi bir performans sergilediğini gösterir.

- R^2 arttı.
- Varyans homojenliği sağlandı.
- Artıklar normal dağılıyor.
- Değişkenler istatistiksel olarak anlamlı.

```
> bptest(wls_final_model)

        studentized Breusch-Pagan test

data:  wls_final_model
BP = 3.8381, df = 9, p-value = 0.9217
```

```
> shapiro.test(wls_final_model$residuals)

        Shapiro-Wilk normality test

data:  wls_final_model$residuals
W = 0.99665, p-value = 0.1366
```

Genelleştirilmiş Doğrusal Model

```
> glm_model <- glm(Basınç_Dayanımı~Çimento + Yüksek_Fırın_Cürufu+ Uçucu_Kül+
Su+ Süper_Akışkanlaştırıcı+ İri_Agrega+ İnce_Agrega + Kür_Süresi,
+                  train_clean,
+                  weights = weights_wls, family = Gamma(link = "log"))
> summary(glm_model)

Call:
glm(formula = Basınç_Dayanımı ~ Çimento + Yüksek_Fırın_Cürufu +
    Uçucu_Kül + Su + Süper_Akışkanlaştırıcı + İri_Agrega + İnce_Agrega +
    Kür_Süresi, family = Gamma(link = "log"), data = train_clean,
    weights = weights_wls)

Coefficients:
                      Estimate Std. Error t value Pr(>|t|)
(Intercept)           1.8725391  1.0437091   1.794   0.0732 .
Çimento               0.0042064  0.0003429  12.268  < 2e-16 ***
Yüksek_Fırın_Cürufu   0.0031457  0.0003995   7.875 1.28e-14 ***
Uçucu_Kül             0.0029560  0.0004875   6.064 2.16e-09 ***
Su                   -0.0039929  0.0015677  -2.547   0.0111 *
Süper_Akışkanlaştırıcı  0.0163500  0.0039573   4.132 4.03e-05 ***
İri_Agrega            0.0004537  0.0003610   1.257   0.2092
İnce_Agrega          -0.0000873  0.0004215  -0.207   0.8360
Kür_Süresi            0.0080963  0.0003246  24.942  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for Gamma family taken to be 0.001724049)

    Null deviance: 4.2183  on 719  degrees of freedom
Residual deviance: 1.4103  on 711  degrees of freedom
AIC: 112.14

Number of Fisher Scoring iterations: 7
```

Modelin genel değerlendirmesi:

- AIC: 112.14
- RMSE: 44.9188
- Üç değişken istatistiksel olarak anlamlı değil.

Modellerin Karşılaştırılması

	Model	RMSE	Adj_R2
1	Alternatif Model	19.141000	0.6493248
2	Stepwise Model	10.643733	0.7421005
3	WLS	11.282577	0.7687560
4	WLS Final Model	7.116883	0.8662449
5	GLM	44.918827	NA

	df	AIC
alternatif_model	10	427.3553
step_model	8	5085.5093
wls_model	10	5008.2997
wls_final_model	11	4615.1127
glm_model	10	112.1378

```
> bp_results
             Model BP_statistic      p_value
1 Alternatif Model    34.779645 2.932590e-05
2   Stepwise Model    74.404687 5.089499e-14
3              WLS     3.135893 9.255421e-01
4        WLS Final     3.838135 9.217393e-01
5              GLM           NA           NA
```

```
> shapiro_results
             Model W_statistic      p_value
1 Alternatif Model   0.9435164 6.328922e-16
2   Stepwise Model   0.9954874 3.398878e-02
3              WLS   0.9871352 5.823401e-06
4        WLS Final   0.9966523 1.365926e-01
5              GLM          NA           NA
```

Final Modelin Varsayım Kontrolleri

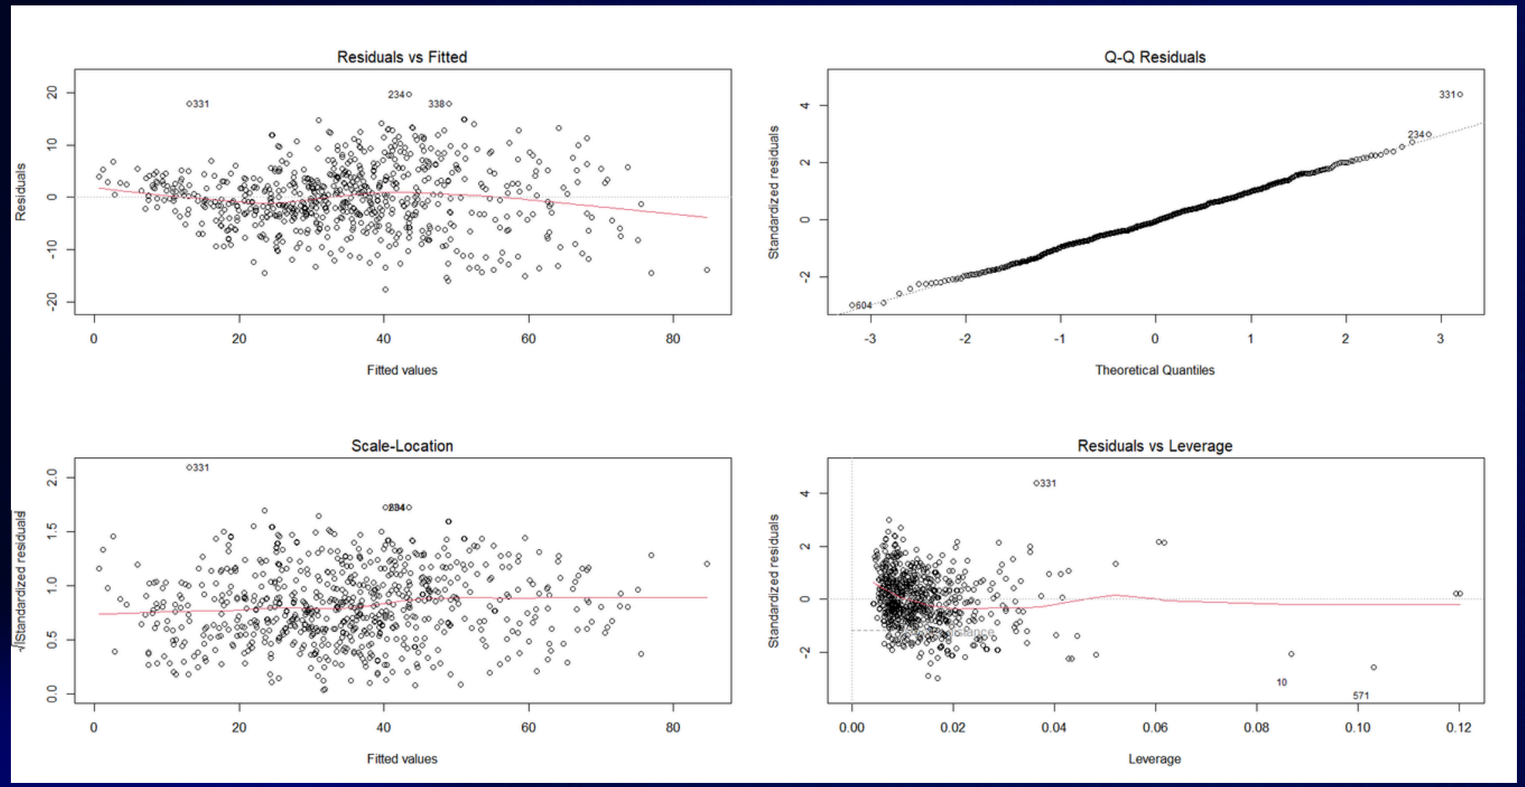

- **Residuals vs Fitted (Artıklar – Tahminler)**

Artıklar genel olarak 0 etrafında rastgele dağılmış. LOESS eğrisi büyük ölçüde yatay, ancak yüksek fitted değerlerde hafif bir aşağı eğilim var.

- **Q–Q Plot (Artıkların Normalliği)**

Sağ üst uçta birkaç gözlem (331, 234) hafif sapma gösteriyor. Artıklar genel olarak normal dağılıma oldukça yakın.

- **Scale–Location (Varyans Homojenliği)**

Hata varyansı büyük ölçüde sabit.

- **Residuals vs Leverage (Etkili Gözlemler)**

Birkaç gözlem (örn. 571, 331) daha yüksek leverage'a sahip ancak Cook's Distance sınırlarını kritik düzeyde aşmıyor.

Final Modelin Varsayım Kontrolleri

```
> bptest(wls_final_model)

        studentized Breusch-Pagan test

data:  wls_final_model
BP = 3.8381, df = 9, p-value = 0.9217
```

```
> shapiro.test(wls_final_model$residuals)

        Shapiro-Wilk normality test

data:  wls_final_model$residuals
W = 0.99665, p-value = 0.1366
```

```
> anova(wls_final_model)
Analysis of Variance Table

Response: Basınç_Dayanımı
                       Df Sum Sq Mean Sq   F value    Pr(>F)
Çimento                 1 751.30  751.30 1306.6860 < 2.2e-16 ***
Yüksek_Fırın_Cürufu     1 273.18  273.18  475.1227 < 2.2e-16 ***
Uçucu_Kül               1 484.37  484.37  842.4343 < 2.2e-16 ***
poly(Su, 2)             2 207.07  103.54  180.0719 < 2.2e-16 ***
Süper_Akışkanlaştırıcı  1  16.48   16.48   28.6694  1.16e-07 ***
İri_Agrega              1   3.80    3.80    6.6139  0.010321 *
İnce_Agrega             1   5.43    5.43    9.4498  0.002193 **
log(Kür_Süresi)         1 940.86  940.86 1636.3779 < 2.2e-16 ***
Residuals             710 408.23    0.57
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

```
> vif(wls_final_model)
                          GVIF Df GVIF^(1/(2*Df))
Çimento                7.774279  1        2.788239
Yüksek_Fırın_Cürufu    8.310267  1        2.882753
Uçucu_Kül              7.506410  1        2.739783
poly(Su, 2)            7.618387  2        1.661368
Süper_Akışkanlaştırıcı 3.231883  1        1.797744
İri_Agrega             5.589612  1        2.364236
İnce_Agrega            8.062001  1        2.839366
log(Kür_Süresi)        1.065976  1        1.032461
```

- Breusch–Pagan testi sonucu (p = 0.9217), modelde hata varyansının sabit olduğunu ve varyans homojenliği varsayımının sağlandığını göstermektedir. Shapiro–Wilk testi (p = 0.1366) artıkların normal dağıldığını ve normallik varsayımının ihlal edilmediğini ortaya koymaktadır. VIF değerleri incelendiğinde, bağımsız değişkenler arasında yüksek düzeyde bir ilişki bulunmadığı, dolayısıyla modelde çoklu doğrusal bağlantı (multicollinearity) sorunu olmadığı anlaşılmaktadır. Sonuç olarak, model temel regresyon varsayımlarını başarıyla sağlamakta ve istatistiksel açıdan güvenilir bir yapı sergilemektedir.

%95 Güven Aralıkları :

```
> confint(wls_final_model)
                                  2.5 %       97.5 %
(Intercept)                -133.84283079 -76.99812367
Çimento                       0.12770484   0.15228366
Yüksek_Fırın_Cürufu           0.10411153   0.13281076
Uçucu_Kül                     0.07338908   0.10839123
poly(Su, 2)1                -89.55375101 -28.46968045
poly(Su, 2)2                 16.95338853  43.14413843
Süper_Akışkanlaştırıcı        0.01750499   0.31080519
İri_Agrega                    0.01756798   0.04350921
İnce_Agrega                   0.02666964   0.05711286
log(Kür_Süresi)               7.63439358   8.41325211
```

- Final modeline ait %95 güven aralıkları, modele dahil edilen tüm bağımsız değişkenlerin basınç dayanımı üzerindeki etkilerinin istatistiksel olarak anlamlı olduğunu göstermektedir.

Model Performansı: Test Setinde Gerçek–Tahmin Uyumu

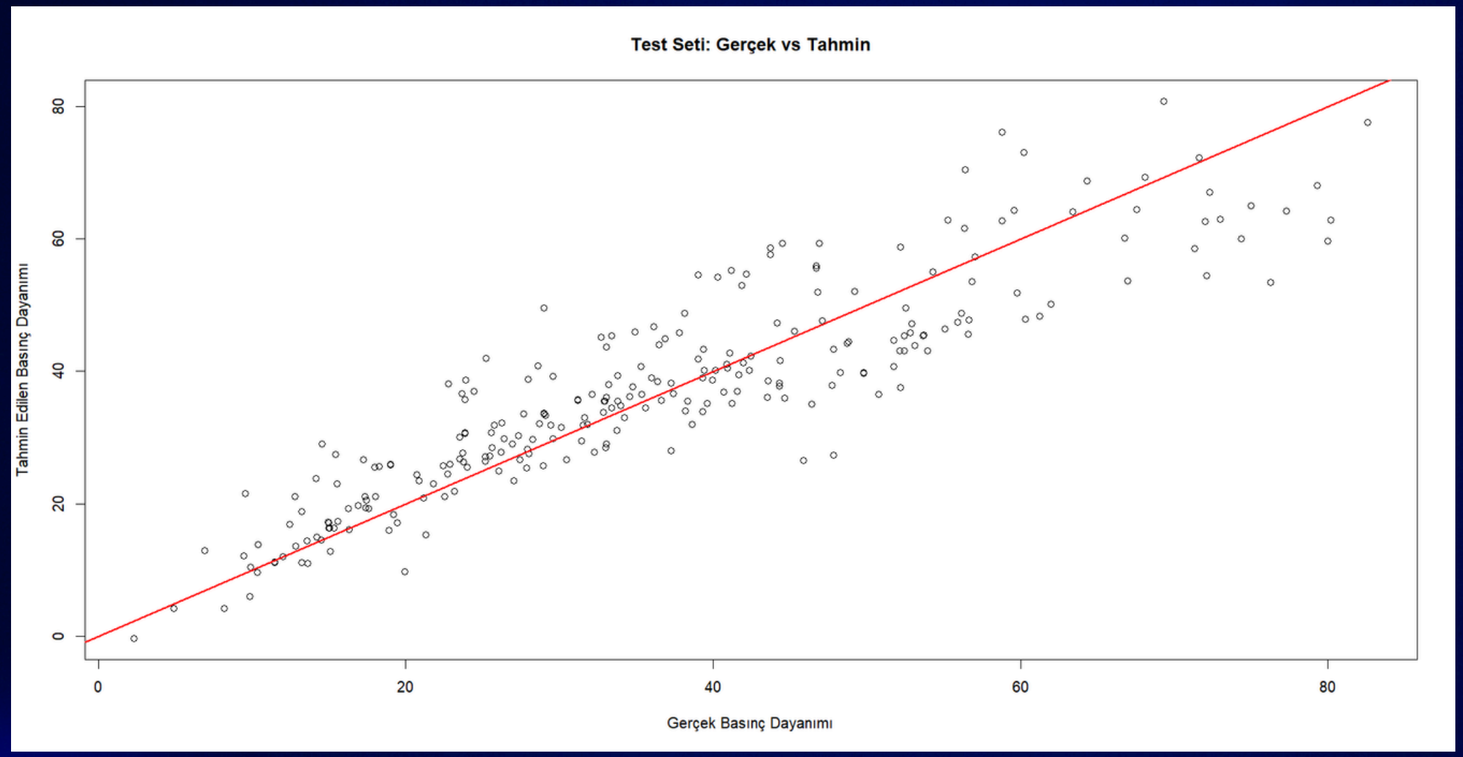


```
> R2_test
[1] 0.8125598
```

```
> rmse
[1] 7.644112
```

```
> mae
[1] 5.866818
```

- Test setinde gerçek ve tahmin edilen basınç dayanımı değerleri arasında güçlü ve pozitif bir doğrusal ilişki gözlenmektedir. Noktaların büyük kısmının referans doğrusu etrafında toplanması, modelin genel olarak başarılı tahminler ürettiğini göstermektedir. Modelin test seti performansı $R^2 = 0.8125$ olup, basınç dayanımındaki değişimin önemli bir kısmının model tarafından açıklandığını göstermektedir. RMSE = 7.64 ve MAE = 5.87 değerleri, modelin test verisi üzerinde kabul edilebilir hata düzeyine sahip olduğunu göstermektedir.

Yeni Bir Gözlem için %95 Güven ve Kestirim Aralığı:

```
> new_obs <- data.frame(
+   Çimento = 281,
+   Yüksek_Fırın_Cürufu = 73,
+   Uçucu_Kül = 54,
+   Su = 181,
+   Süper_Akışkanlaştırıcı = 6,
+   İri_Agrega = 972,
+   İnce_Agrega = 773,
+   Kür_Süresi = 45)
```

```
> print(point_pred)
       1
40.42987
```

```
%95 Güven Aralığı (Confidence Interval):
> print(ci_95)
       fit    lwr      upr
1 40.42987 39.776 41.08374
```

```
%95 Kestirim Aralığı (Prediction Interval):
> print(pi_95)
       fit      lwr      upr
1 40.42987 38.80389 42.05585
```

- Yeni gözlem için yapılan tahminde, model basınç dayanımını 40.43 olarak öngörmektedir.
- %95 güven aralığı [39.776, 41.083], bu koşullar altında ortalama basınç dayanımının bu aralıkta yer almasının beklendiğini göstermektedir.
- %95 kestirim aralığı [38.80, 42.06], tek bir yeni gözlemin alabileceği değerleri kapsamakta olup, bireysel gözlemlerdeki rastlantısal değişkenlik nedeniyle güven aralığına kıyasla daha geniştir.

Modeli Geliştirmek Üzere Görüş ve Öneriler

- Final modelinin açıklayıcılığı yüksek olmakla birlikte ($R^2 = 0.8679$), alternatif modelleme yaklaşımları ile sonuçların daha derinlemesine değerlendirilmesi mümkündür.

- Makine öğrenmesi temelli yöntemlerle karşılaştırmalı analizler yapılması, çalışmanın kapsamını genişletebilir.

- Mevcut modelde değişkenler bağımsız olarak ele alınmıştır. Gelecek çalışmalarda, modelin açıklayıcılığını (R^2) artırmak için 'Su/Bağlayıcı Oranı' (Su / [Çimento + Cüruf + Kül]) gibi alan bilgisine dayalı türetilmiş değişkenler modele eklenebilir.

Kaynakça

- DEÜ ders kaynakları
- https://youtu.be/9Q5ErbQF_vk?si=LJ-SLaF7Ba0igbIA
- https://youtu.be/IJwxMXvGtWs?si=V2vF-efaHcDxYmSN
- https://www.kaggle.com/datasets/ainalirham/mutubeton/data

```
Sys.setlocale("LC_ALL", "Turkish")

library(readxl)

data<-Beton1

data <- data |>

  dplyr::mutate(across(where(is.numeric), ~ .x + 0.001))

str(data)

summary(data)

head(data)

sapply(data, class)


hist(data$Basınç_Dayanımı)

shapiro.test(data$Basınç_Dayanımı)

boxplot(data$Basınç_Dayanımı)


hist(data$Çimento)

hist(data$Yüksek_Fırın_Cürufu)

hist(data$Uçucu_Kül)

hist(data$Su)

hist(data$Süper_Akışkanlaştırıcı)

hist(data$İri_Agrega)

hist(data$İnce_Agrega)

hist(data$Kür_Süresi)


#matrix plot çizimi

matrix_data=cbind(data$Basınç_Dayanımı,data$Çimento,data$Yüksek_Fırın_Cürufu,data$Uçucu_Kül
,data$Su,data$Süper_Akışkanlaştırıcı,data$İri_Agrega, data$İnce_Agrega, data$Kür_Süresi)

colnames(matrix_data) <-
c("Basınç_Dayanımı","Çimento","Yüksek_Fırın_Cürufu","Uçucu_Kül","Su","Süper_Akışkanlaştırıcı","İri
_Agrega","İnce_Agrega","Kür_Süresi")

pairs(matrix_data, pch = 19, col='red', lower.panel = NULL)


cor(data)
```

```
library(corrplot)
corrplot(cor(data))

plot(data)

smp_size <- floor(0.75 * nrow(data)) ##floor sayinin tam kismini alir##
set.seed(123) ## ayni rassal sayilarin t retilmesini saglar.###
train_ind <- sample(nrow(data), size = smp_size, replace = FALSE)
train <- data[train_ind, ]
test <- data[-train_ind, ]
dim(train)
dim(test)

#İlk Model
model<-lm(Basınç_Dayanımı~Çimento + Yüksek_Fırın_Cürufu+ Uçucu_Kül+ Su+
Süper_Akışkanlaştırıcı+ İri_Agrega+ İnce_Agrega + Kür_Süresi,train)
summary(model)
model$coefficients
library(car)
vif(model)
anova(model)
library(lmtest)
bptest(model)

par(mfrow = c(2,2))
plot(model)
par(mfrow = c(1,1))

#Standartlaştırılmış artıklar (|r| > 3)
rstd <- rstandard(model)
```

```
outlier_rstd <- which(abs(rstd) > 3)

cat("Artık temelli aykırı gözlem sayısı:", length(outlier_rstd), "\n")

#Cook's Distance
cooksd <- cooks.distance(model)
n <- nrow(train)
esik_deger <- 4 / n

plot(cooksd, pch="*", cex=2, main="Etkili Gözlemler (Cook's Distance)")
abline(h = esik_deger, col="red")



plot(cooksd,
    pch = 1,        # boş daire
    cex = 0.8,
    main = "(Cook's Distance)",
    ylab = "Cook's Distance",
    xlab = "Index")

abline(h = esik_deger, col = "red", lwd = 2)

outlier_cook <- which(cooksd > esik_deger)
cat("Cook's Distance ile bulunan gözlem sayısı:", length(outlier_cook), "\n")



#İki yöntemi birleştir
outlier_all <- union(outlier_rstd, outlier_cook)
cat("Toplam silinecek gözlem sayısı:", length(outlier_all), "\n")
```

```
#Train setini temizle
if (length(outlier_all) > 0) {
  train_clean <- train[-outlier_all, ]
  cat(length(outlier_all), "adet aykırı/etkili gözlem silindi.\n")
} else {
  train_clean <- train
  cat("Aykırı veya etkili gözlem bulunamadı.\n")
}

cat("Silinen gözlem sayısı:", nrow(train) - nrow(train_clean), "\n")



#Temiz veriyle modeli yeniden kur
model_clean<- lm(Basınç_Dayanımı ~ Çimento + Yüksek_Fırın_Cürufu + Uçucu_Kül +
                   Su + Süper_Akışkanlaştırıcı + İri_Agrega + İnce_Agrega + Kür_Süresi,
                 data = train_clean)
summary(model_clean)
shapiro.test(model_clean$residuals)
bptest(model_clean)

#Bağımlı değişkene log dönüşümü modeli
alternatif_model <- lm(log(Basınç_Dayanımı) ~ Çimento + Yüksek_Fırın_Cürufu + Uçucu_Kül +
                 Su + Süper_Akışkanlaştırıcı + İri_Agrega + İnce_Agrega + Kür_Süresi,
               data = train_clean)

summary(alternatif_model)
shapiro.test(alternatif_model$residuals)
bptest(alternatif_model)

hist(train_clean$Basınç_Dayanımı)
boxplot(train_clean$Basınç_Dayanımı)
```

```
#Stepwise Model
# Null model (sabit terim)
null_model <- lm(Basınç_Dayanımı ~ 1, data = train_clean)
# Tüm doğrusal değişkenleri içeren aday model
full_linear <- lm(
  Basınç_Dayanımı ~
    Çimento +
    Yüksek_Fırın_Cürufu +
    Uçucu_Kül +
    Su +
    Süper_Akışkanlaştırıcı +
    İri_Agrega +
    İnce_Agrega +
    Kür_Süresi,
  data = train_clean
)
# Stepwise (AIC) – sadece doğrusal terimler
step_model <- step(
  null_model,
  scope = list(lower = null_model, upper = full_linear),
  direction = "both",
  trace = 1
)
# Nihai stepwise modeli
summary(step_model)
formula(step_model)
bptest(step_model)
vif(step_model)
shapiro.test(step_model$residuals)
```

```
#WLS Model
res2 <- resid(model_clean)^2
fit  <- fitted(model_clean)
var_model <- lm(res2 ~ fit)
summary(var_model)
weights_wls <- 1 / fitted(var_model)
weights_wls[weights_wls <= 0] <- min(weights_wls[weights_wls > 0])
wls_model <- lm(
  Basınç_Dayanımı~Çimento + Yüksek_Fırın_Cürufu+ Uçucu_Kül+ Su+ Süper_Akışkanlaştırıcı+
İri_Agrega+ İnce_Agrega + Kür_Süresi,
  train_clean,
  weights = weights_wls
)
summary(wls_model)
library(lmtest)
bptest(wls_model)
vif(wls_model)
shapiro.test(wls_model$residuals)

#GLM Model
glm_model <- glm(Basınç_Dayanımı~Çimento + Yüksek_Fırın_Cürufu+ Uçucu_Kül+ Su+
Süper_Akışkanlaştırıcı+ İri_Agrega+ İnce_Agrega + Kür_Süresi,
                 train_clean,
                 weights = weights_wls, family = Gamma(link = "log"))
summary(glm_model)
bptest(glm_model)
shapiro.test(glm_model$residuals)

#Final Model
wls_final_model <- lm(
```

```
  Basınç_Dayanımı~Çimento + Yüksek_Fırın_Cürufu+ Uçucu_Kül+ poly(Su, 2)+ Süper_Akışkanlaştırıcı+
İri_Agrega+ İnce_Agrega + log(Kür_Süresi),
  train_clean,
  weights = weights_wls
)
summary(wls_final_model)
library(lmtest)
bptest(wls_final_model)
vif(wls_final_model)
shapiro.test(wls_final_model$residuals)
anova(wls_final_model)

par(mfrow = c(2,2))
plot(wls_final_model)
par(mfrow = c(1,1))

###Güven ve Tahmin Aralıkları###
confint(wls_final_model)
confint(wls_final_model,level=0.90)

#Modellerin karşılaştırılması
train$pred_log <- exp(predict(alternatif_model, newdata = train))
train$pred_step <- predict(step_model, newdata = train)
train$pred_wls <- predict(wls_model, newdata = train)
train$pred_wls_final <- predict(wls_final_model, newdata = train)
train$pred_glm <- predict(glm_model, newdata = train, type = "response")

# RMSE fonksiyonu
rmse_fun <- function(y, yhat) {
  sqrt(mean((y - yhat)^2))
}
```

```
train_perf <- data.frame(
  Model = c("Alternatif Model", "Stepwise Model", "WLS", "WLS Final Model", "GLM"),

  RMSE = c(
    rmse_fun(train$Basınç_Dayanımı, train$pred_log),
    rmse_fun(train$Basınç_Dayanımı, train$pred_step),
    rmse_fun(train$Basınç_Dayanımı, train$pred_wls),
    rmse_fun(train$Basınç_Dayanımı, train$pred_wls_final),
    rmse_fun(train$Basınç_Dayanımı, train$pred_glm)
  )
)

train_perf
adjR2 <- c(
  summary(alternatif_model)$adj.r.squared,
  summary(step_model)$adj.r.squared,
  summary(wls_model)$adj.r.squared,
  summary(wls_final_model)$adj.r.squared,
  NA  # GLM için klasik R² yok
)

train_perf$Adj_R2 <- adjR2
train_perf

AIC(
  alternatif_model,
  step_model,
  wls_model,
  wls_final_model,
  glm_model
```

```
)

library(lmtest)

bp_results <- data.frame(
  Model = c("Alternatif Model", "Stepwise Model","WLS", "WLS Final", "GLM"),
  BP_statistic = c(
    bptest(alternatif_model)$statistic,
    bptest(step_model)$statistic,
    bptest(wls_model)$statistic,
    bptest(wls_final_model)$statistic,
    NA
  ),
  p_value = c(
    bptest(alternatif_model)$p.value,
    bptest(step_model)$p.value,
    bptest(wls_model)$p.value,
    bptest(wls_final_model)$p.value,
    NA
  )
)

bp_results


# Artıkların Shapiro-Wilk testi sonuçları
shapiro_results <- data.frame(
  Model = c("Alternatif Model", "Stepwise Model","WLS", "WLS Final", "GLM"),
  W_statistic = c(
    shapiro.test(alternatif_model$residuals)$statistic,
    shapiro.test(step_model$residuals)$statistic,
```

```
    shapiro.test(wls_model$residuals)$statistic,
    shapiro.test(wls_final_model$residuals)$statistic,
    NA
  ),
  p_value = c(
    shapiro.test(alternatif_model$residuals)$p.value,
    shapiro.test(step_model$residuals)$p.value,
    shapiro.test(wls_model$residuals)$p.value,
    shapiro.test(wls_final_model$residuals)$p.value,
    NA
  )
)

shapiro_results



#TEST seti kontrol
test$pred <- predict(wls_final_model, newdata = test)
rmse <- sqrt(mean((test$Basınç_Dayanımı - test$pred)^2))
rmse
SSE <- sum((test$Basınç_Dayanımı - test$pred)^2)
SST <- sum((test$Basınç_Dayanımı - mean(test$Basınç_Dayanımı))^2)
R2_test <- 1 - SSE / SST
R2_test
plot(test$Basınç_Dayanımı, test$pred,
     xlab = "Gerçek Basınç Dayanımı",
     ylab = "Tahmin Edilen Basınç Dayanımı",
     main = "Test Seti: Gerçek vs Tahmin")

abline(0, 1, col = "red", lwd = 2)
```

```
test$residuals <- test$Basınç_Dayanımı - test$pred

hist(test$residuals, main = "Test Artıkları Histogramı")
plot(test$pred, test$residuals,
    xlab = "Tahmin",
    ylab = "Artık",
    main = "Test Artıkları vs Tahmin")
abline(h = 0, col = "red")
mae <- mean(abs(test$Basınç_Dayanımı - test$pred))
mae



#Yeni bir gözlem değeri için %95'lik güven aralığını ve kestirim aralığını bul
# Yeni gözlem (örnek değerler)
new_obs <- data.frame(
  Çimento = 281,
  Yüksek_Fırın_Cürufu = 73,
  Uçucu_Kül = 54,
  Su = 181,
  Süper_Akışkanlaştırıcı = 6,
  İri_Agrega = 972,
  İnce_Agrega = 773,
  Kür_Süresi = 45)


# Nokta tahmini
point_pred <- predict(wls_final_model, newdata = new_obs)

# %95 Güven Aralığı (ortalama için)
ci_95 <- predict(
```

```
  wls_final_model,
  newdata = new_obs,
  interval = "confidence",
  level = 0.95
)

# %95 Kestirim Aralığı (yeni gözlem için)
pi_95 <- predict(
  wls_final_model,
  newdata = new_obs,
  interval = "prediction",
  level = 0.95
)

# Sonuçlar
cat("Nokta Tahmini (Ortalama):\n")
print(point_pred)

cat("\n%95 Güven Aralığı (Confidence Interval):\n")
print(ci_95)

cat("\n%95 Kestirim Aralığı (Prediction Interval):\n")
print(pi_95)
```